

权 利 要 求 书

1、一种三阶段特征增强心肌梗死定位方法，其特征在于，包括：

步骤 1，以预设的采样率对原始心电图数据进行采样，得到样本数据集；

步骤 2，对样本数据集进行数据增强后得到训练集，其中，所述数据增强包括随机裁剪和拉长处理；

所述步骤 2 具体包括：

步骤 2.1，根据样本类别的数量将样本数据集分为多数类样本和少数类样本；

步骤 2.2，对少数类样本进行随机裁剪和拉长处理生成新的样本加入样本数据集，形成训练集；

步骤 3，利用训练集进行初始模型一阶段训练，生成导联贡献图；

所述步骤 3 具体包括：

步骤 3.1，将训练集输入初始模型，对训练集中每个导联和预设数量分类任务生成贡献分数；

步骤 3.2，针对少数类样本，将每个导联的分数整理为对应的多维向量，其中，所述向量的维度与少数类样本的样本类别的数量相同；

步骤 3.3，筛选出贡献分数超过阈值的导联，在筛选出的导联向量间，使用皮尔逊相关系数计算每对导联贡献向量的相似性；

步骤 3.4，在相关性最高的导联对之间建立边，形成导联贡献图；

步骤 4，使用训练集中少数类样本和导联贡献图进行初始模型二阶段训练，使用加权二分类交叉熵损失函数进行反向传播更新初始模型参数并冻结初始模型中骨干网络的部分网络参数；

步骤 5，利用训练集和导联贡献图进行初始模型三阶段训练，使用加权二分类交叉熵损失函数进行反向传播更新初始模型中的图时空交叉注意力网络的网络参数并结合训练好的骨干网络和多分支分类结构形成目标模型；

步骤 6，将目标心电图数据输入优化后的目标模型，得到定位结果。

2、根据权利要求 1 所述的方法，其特征在于，所述皮尔逊相关系数的表达式为

$$r(V_j, V_k) = \frac{\sum_{i=1}^4 (v_{j,i} - \bar{v}_j)(v_{k,i} - \bar{v}_k)}{\sqrt{\sum_{i=1}^4 (v_{j,i} - \bar{v}_j)^2} \cdot \sqrt{\sum_{i=1}^4 (v_{k,i} - \bar{v}_k)^2}}$$

其中， V_j 和 V_k 为导联贡献向量， $\bar{v}_j$ 和 $\bar{v}_k$ 分别为向量 V_j 和 V_k 的均值， $v_{j,i}$ 表示向量 j 的第 i 个分量， $v_{k,i}$ 表示向量 k 的第 i 个分量。

3、根据权利要求2所述的方法，其特征在于，所述步骤4具体包括：

步骤4.1，将训练集中少数类样本和导联贡献图输入初始模型，得到少数类样本的预测值；

步骤4.2，将预测值和少数类样本对应的真实值代入加权二分类交叉熵损失函数进行反向传播更新初始模型参数并冻结初始模型中骨干网络的部分网络参数，其中，所述加权二分类交叉熵损失函数为

$$L = \sum_{c=1}^n L_c$$

$$L_c = -w_c(y_c \log(\hat{y}_c) + (1 - y_c) \log(1 - \hat{y}_c))$$

其中， n 表示分类任务的数量， L_c 是第 c 类别的损失， w_c 是第 c 类别的权重， y_c 表示真实标签， $\hat{y}_c$ 表示初始模型预测的概率输出；

所述更新初始模型参数的表达式为

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L$$

其中 θ 为模型参数， η 为学习率， $\nabla_{\theta} L$ 为损失函数对模型参数的梯度。

4、根据权利要求3所述的方法，其特征在于，所述骨干网络包括多个卷积块，每个卷积块包括跳跃连接层、批归一化层、激活函数、压缩与激励层和池化层；

所述图时空交叉注意力网络包括图卷积网络、图注意力网络和Transformer编码器，所述Transformer编码器包括输入和输出的线性投影、Transformer编码层、层归一化和Dropout操作，所述Transformer编码层包括多头自注意力机制和前馈神经网络。

5、根据权利要求4所述的方法，其特征在于，所述步骤5具体包括：

步骤5.1，将训练集输入骨干网络，跳跃连接层将未变换的输入直接加入

到输出中，批归一化层通过标准化特征分布得到特征图，压缩与激励层通过全局平均池化提取全局特征并动态调整通道权重以增强重要特征，池化层使用全局平均池化将特征图压缩为全局描述，并计算缩放系数，对特征图进行缩放调整，得到编码后的导联特征，其中，所述编码后的导联特征的表达式为

$$F' = \text{Pool}(F \cdot \text{sigmoid}(W_2 \cdot \text{ReLU}(W_1 \cdot \text{GAP}(F))))$$

其中， W_1 和 W_2 是全连接层的权重矩阵， F 表示特征图， GAP 表示全局平均池化操作， Pool 表示对特征图进行压缩降维的池化操作；

步骤 5.2，图卷积网络利用导联贡献图构建无向图，并基于无向图的邻接矩阵通过逐层更新节点的特征来聚合邻接导联特征的信息，形成全局表示特征，其中，所述全局表示特征的表达式为

$$H^{(l+1)} = \sigma(D^{-1/2}AD^{-1/2}H^{(l)}W^{(l)})$$

其中， $H^{(l)}$ 是第 l 层的特征表示， $H^{(0)} = X$ ， X 表示输入的导联特征， $W^{(l)}$ 是第 l 层的权重矩阵， D 是邻接矩阵 A 的度矩阵，定义为 $D_{ii} = \sum_j A_{ij}$ ， σ 是激活函数；

步骤 5.3，构建全连接图，其中，所述全连接图中每个导联节点与其他所有导联节点相连；

步骤 5.4，图注意力网络基于全连接图根据导联特征间的重要性自动调整注意力权重，根据调整后的注意力权重得到聚合特征，其中，所述聚合特征的表达式为

$$h'_i = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} W h_j \right)$$

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(a^T [W h_i || W h_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(a^T [W h_i || W h_k]))}$$

其中，权重 α_{ij} 表示节点 j 对节点 i 的影响力， h_i 是节点 i 的输入特征向量， W 是可学习的线性变换矩阵，用于特征映射， a 是可学习的注意力权重向量， $\mathcal{N}(i)$ 是节点的邻居集合， σ 是非线性激活函数， LeakyReLU 是分段线性激活函

数；

步骤 5.5，将输入的导联特征 X 通过线性投影映射到隐藏维度，并与相对位置编码相加，随后经过层归一化和 Dropout 处理，多头注意力机制将不同头的注意力结果拼接后通过线性变换输出；

步骤 5.6，将全局表示特征、聚合特征、线性变换输出的特征和编码后的导联特征输入多分支分类结构得到预测值；

步骤 5.7，将预测值和真实值代入加权二分类交叉熵损失函数进行反向传播更新图时空交叉注意力网络的网络参数；

步骤 5.8，结合训练好的图时空交叉注意力网络、训练好的骨干网络和多分支分类结构形成目标模型。